

Control 4

Integrantes: Adolfo Rojas V.
Profesor: Juan Manuel Barrios
Ayudantes: Andrés Calderón
Martina Navarro
Scarleth Betancurt
Sebastián Sáez

Fecha de realización: 23 de julio de 2025
Fecha de entrega: 23 de julio de 2025
Santiago de Chile

1. Semana 13 (LSH)

a. A continuación la tabla con la notación unaria para $\mathbf{R}$ y $\mathbf{Q}$

Tabla 1: Notación unaria

Punto	unaria(x)	unaria(y)	HS(·)
$a = (0, 3)$	00000	11100	0000011100
$b = (0, 5)$	00000	11111	0000011111
$c = (1, 2)$	10000	11000	1000011000
$d = (2, 4)$	11000	11110	1100011110
$e = (4, 1)$	11110	10000	1111010000
$f = (5, 0)$	11111	00000	1111100000
$g = (5, 3)$	11111	11100	1111111100
$h = (5, 5)$	11111	11111	1111111111
$q_1 = (1, 4)$	10000	11110	1000011110
$q_2 = (5, 2)$	11111	11000	1111111000

b. Aquí la continuación junto con las 3 proyecciones pedidas para ambos conjuntos

Tabla 2: Proyecciones

Punto	HS(·)		Proyecciones		
	unaria(x)	unaria(y)	$\{1, 3, 8\}$	$\{2, 5, 9\}$	$\{3, 7, 10\}$
$a = (0, 3)$	00000	11100	001	000	010
$b = (0, 5)$	00000	11111	001	001	011
$c = (1, 2)$	10000	11000	100	000	010
$d = (2, 4)$	11000	11110	101	101	010
$e = (4, 1)$	11110	10000	110	100	100
$f = (5, 0)$	11111	00000	110	110	100
$g = (5, 3)$	11111	11100	111	110	110
$h = (5, 5)$	11111	11111	111	111	111
$q_1 = (1, 4)$	10000	11110	101	001	010
$q_2 = (5, 2)$	11111	11000	110	110	110

c. Para apoyarnos hacemos una tabla con las colisiones entre las proyecciones de cada elemento de $\mathbf{R}$ con las queries y calculamos las distancias entre los elementos que no fueron descartados para el desempate. De aquí vemos que para nuestras hash-functions el vecino más cercano de q_1 es d mientras que para q_2 es g

Tabla 3: Colisiones y distancias

Punto	Colisiones		Distancias (L_1)	
	q_1	q_2	q_1	q_2
$a = (0, 3)$	1	0	2	-
$b = (0, 5)$	1	0	2	-
$c = (1, 2)$	1	0	2	-
$d = (2, 4)$	2	0	1	-
$e = (4, 1)$	0	1	-	2
$f = (5, 0)$	0	2	-	2
$g = (5, 3)$	0	2	-	1
$h = (5, 5)$	0	0	-	-

2. Semana 13 (PCA)

- Ordenamos y nos quedamos con la varianza/valor propio más grande de $\mathbf{C}$ el cual sería $\lambda_4 = 11.1$ con lo cual $\mathbf{W} = v_4$
- $\frac{\lambda_4}{\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 + \lambda_5} = \frac{11.1}{2.5 + 0.2 + 4.3 + 11.1 + 0.1} \approx 0.61$
- $(q - \bar{1}\mu_q)\mathbf{W}^T = (8 - 4.6) \cdot 0.5 + (3 - 4.6) \cdot 0.3 - (3 - 4.6) \cdot 0.4 + (2 - 4.6) \cdot 0.3 - (7 - 4.6) \cdot 0.6 = -0.36$ luego se escoge $f = -0.4$ dado que es el más cercano

3. Semana 14 (Distancias)

- a. Calculamos las distancias euclidianas (norma $p = 2$) de los vectores respecto a la query:

$$\|q - a\|_2 = \sqrt{(6 - 4)^2 + (4 - 2)^2 + (3 - 5)^2 + (1 - 3)^2 + (3 - 5)^2} \approx 4.47 \quad (1a)$$

$$\|q - b\|_2 = \sqrt{(6 - 6)^2 + (4 - 4)^2 + (3 - 5)^2 + (1 - 9)^2 + (3 - 3)^2} \approx 8.25 \quad (1b)$$

$$\|q - c\|_2 = \sqrt{(6 - 5)^2 + (4 - 5)^2 + (3 - 4)^2 + (1 - 10)^2 + (3 - 3)^2} \approx 9.17 \quad (1c)$$

De aquí concluimos que a es el más cercano a q

- Calculamos una distancia fraccional (norma $p = 0.5$)

$$\|q - a\|_{0.5} = \left[\sqrt{|6 - 4|} + \sqrt{|4 - 2|} + \sqrt{|3 - 5|} + \sqrt{|1 - 3|} + \sqrt{|3 - 5|} \right]^2 = 50 \quad (2a)$$

$$\|q - b\|_{0.5} = \left[\sqrt{|6 - 6|} + \sqrt{|4 - 4|} + \sqrt{|3 - 5|} + \sqrt{|1 - 9|} + \sqrt{|3 - 3|} \right]^2 = 18 \quad (2b)$$

$$\|q - c\|_{0.5} = \left[\sqrt{|6 - 5|} + \sqrt{|4 - 5|} + \sqrt{|3 - 4|} + \sqrt{|1 - 10|} + \sqrt{|3 - 3|} \right]^2 = 36 \quad (2c)$$

De aquí concluimos que b es el más cercano a q

- c. Finalmente calculamos la distancia parcial dinámica entre los vectores y la query con $p = 2$ (dist. euclidiana) y escogiendo las $m = 4$ dimensiones con menor diferencia (se eliminan las componentes de las posiciones 5, 4 y 4 para los vectores a, b, c respectivamente)

$$DPF_2^4(q, a) = \sqrt{(6-4)^2 + (4-2)^2 + (3-5)^2 + (1-3)^2} = 4 \quad (3a)$$

$$DPF_2^4(q, b) = \sqrt{(6-6)^2 + (4-4)^2 + (3-5)^2 + (3-3)^2} = 2 \quad (3b)$$

$$DPF_2^4(q, c) = \sqrt{(6-5)^2 + (4-5)^2 + (3-4)^2 + (3-3)^2} \approx 1.73 \quad (3c)$$

De aquí concluimos que c es el más cercano a q

- 2) a. Dados x, y, z vectores (también podrían ser otros elementos como funciones) y d_1, d_2 métricas (por enunciado) tenemos que

$$\begin{aligned} d_3(x, z) &= \frac{d_1(x, z) + d_2(x, z)}{2} \\ &\leq \frac{[d_1(x, y) + d_1(y, z)] + [d_2(x, y) + d_2(y, z)]}{2} \quad \text{des. triangular } d_1, d_2 \\ &\leq \frac{d_1(x, y) + d_2(x, y)}{2} + \frac{d_1(y, z) + d_2(y, z)}{2} \\ &\leq d_3(x, y) + d_3(y, z). \end{aligned}$$

Con lo cual d_3 cumple la desigualdad triangular

- b. Dado el espacio $\mathcal{A} = \{x, y, z\}$ y las distancias d_1, d_2 que son métricas por enunciado. Definimos $d_1(x, y) = d_1(y, z) = 3$, $d_1(x, z) = 1$ y $d_2(x, y) = 3$, $d_2(y, z) = d_2(x, z) = 2$ (notar que no violamos la prop. de desigualdad triangular). Luego vemos que $d_4(x, z) = \min\{d_1(x, z), d_2(x, z)\} = \min\{1, 2\} = 1$ mientras que $d_4(x, y) = \min\{3, 3\} = 3$ y $d_4(y, z) = \min\{3, 2\} = 2$ con lo que tenemos un nuevo set de largos $\{1, 2, 3\}$ pero vemos que no puede existir un triángulo en el plano cartesiano con dichos largos ($1 + 2 \not\geq 3$) por lo que d_4 no cumple la desigualdad triangular

4. Semana 14 (LAESA)

a. A continuación la tabla pivote

Tabla 4: Tabla de pivotes con $P = \{(9, 1)\}$ y $d = \|\cdot\|_1$

R	$\ r_i - (9, 1)\ _1$
$a = (5, 4)$	$ 5 - 9 + 4 - 1 = 7$
$b = (3, 2)$	7
$c = (2, 8)$	14
$d = (5, 7)$	10
$e = (9, 5)$	4
$f = (0, 4)$	12
$g = (8, 9)$	9
$h = (1, 5)$	12
$i = (9, 1)$	0
$j = (9, 7)$	6
$k = (7, 3)$	4
$l = (1, 9)$	16

b. Primero calculamos $\|(9, 1) - q_i\|_1$ lo cual para $q_1 = (2, 3)$ sería 9. Mientras que para $q_2 = (7, 8)$ sería 9 también con lo que $LB = LB_1 = LB_2$. En base a esto podemos ver

Tabla 5: LAESA

R	$d(r, p)$	$LB(r)$	$d(r, q_1)$	NN_1	$d(r, q_2)$	NN_2
$a = (5, 4)$	7	2	4	a	6	a
$b = (3, 2)$	7	2	2	b	10	
$c = (2, 8)$	14	5	-		5	c
$d = (5, 7)$	10	1	7		3	d
$e = (9, 5)$	4	5	-		-	
$f = (0, 4)$	12	3	-		-	
$g = (8, 9)$	9	0	12		2	g
$h = (1, 5)$	12	3	-		-	
$i = (9, 1)$	0	9	-		-	
$j = (9, 7)$	6	3	-		-	
$k = (7, 3)$	4	5	-		-	
$l = (1, 9)$	16	7	-		-	

que el vecino más cercano para q_1 es b , por otro lado, para q_2 es g

- c. La complejidad externa fue de $4 + 5 = 9$ cálculos, la interna se hacen 12 comparaciones con LB por consulta y se calculan 2 distancias query-pivot ($24 + 2 = 26$, 13 por consulta), mientras que con linear scan se hacen 12 cálculos por query (24 cálculos pesados en total), se hacen más cálculos comparado con el método de escaneo completo (pero estos son más ligeros)

5. Semana 15

Varían porque dependen de la distribución de los datos. Si en A hay más agrupamientos, el índice podría funcionar mejor, por otro lado si B tiene una distribución más dispersa, degrada la calidad/eficiencia del índice, aunque ambos tengan igual tamaño y dimensión.